[Week15]_이원주

합성곱 신경망

Convolutional Neural Networks

개념

- 필요성
  - 컴퓨터 비전 `Computer Vision` 분야에서는 다루는 데이터가 이미지라서 크기 ⬆

    ⇒ 합성곱 연산을 사용하여 가중치의 개수를 줄임.

    ▼ 이유

    - 변수 공유 → 필터 하나 가지고 이미지 여기저기랑 여러 번 곱함. 그럼 필터 하나만큼의 변수(=가중치)만 있으면 되잖아.
    - 희소 연결 → Fully connected와 반대되는 개념. 이미지 픽셀 1개는 필터 원소 1개와 곱해지고, 같은 필터의 다른 원소들이랑은 곱해지지 않음.
  - 합성곱을 쓰면 이미지를 몇 픽셀 이동해도 예측 결과가 동일함.

- 사용 분야
  - 컴퓨터 비전
  - 근데 여기서 아이디어 얻어서 음성 인식 같은 다른 분야에서도 쓰임.

[요약]

▼ **합성곱 연산** `convolution operation`

→ 사진 * 필터 = output

여기서 * 연산.

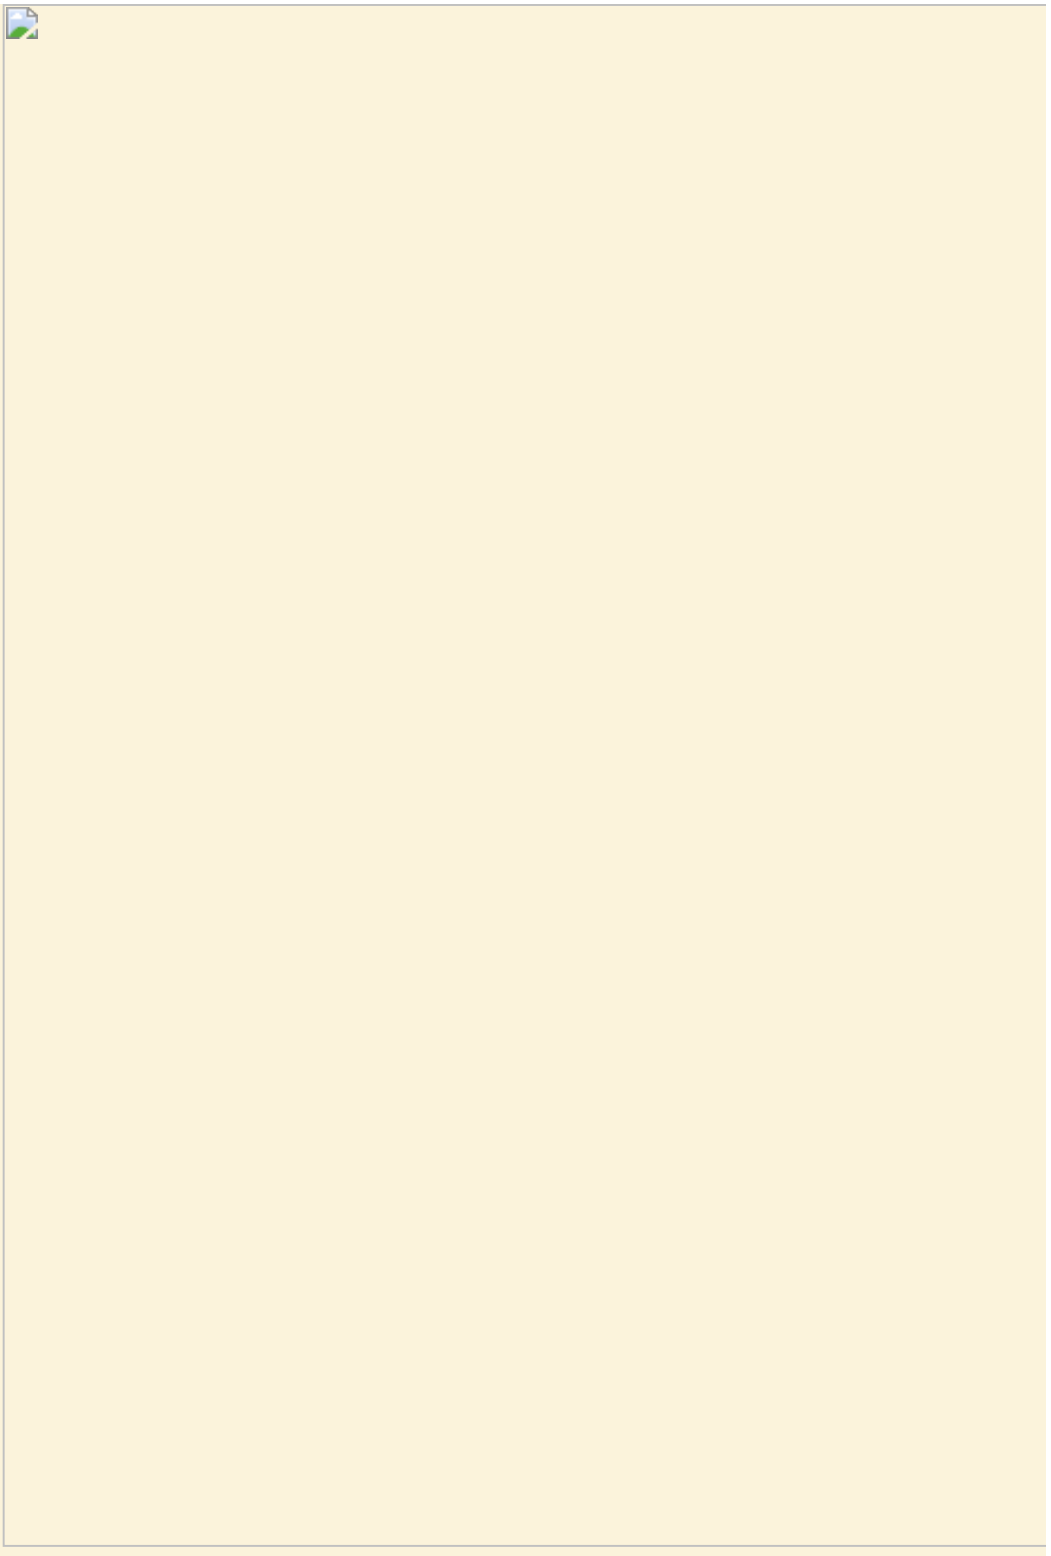

...

▼ tmi

사실 이건 수학적으로 따지면 **교차상관** `cross correlations`(합성곱은 아니고 약
다른 것)인데,

딥러닝 분야에선 관습적으로 합성곱이라고 부름.

▼ **필터 = 커널** `kernel`

윤곽선 검출 `edge detection`

- 필터를 조절해서 사진의 윤곽선(사진의 일부만 나타내는 특징)을 뽑아낼 수 있다

- 용어
  - **수직 윤곽선** → 사진에서 윤곽선 중 수직 방향의 성분
  - **수평 윤곽선**

- 필터의 기본 형태

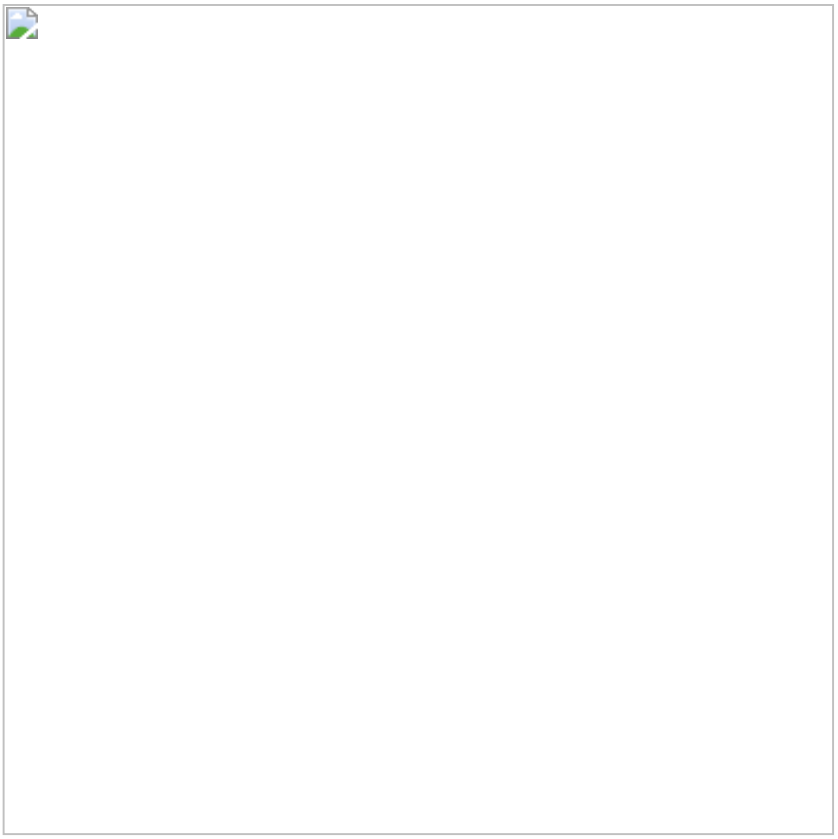

▼ ex) 수직 윤곽선

여기서 수직 윤곽선 → 노란 형광펜

▼ ex) 수직 윤곽선

▼ ex) 수평 윤곽선

    - 초록 : 밝은 쪽(위) → 어두운 쪽(아래)이라 양수
    - 보라 : 반대라서 음수
    - 노랑 : 1,2번째 열은 양수인데 3번째 열이 음수라서 플마 하면 작은 양수

- 다른 필터들

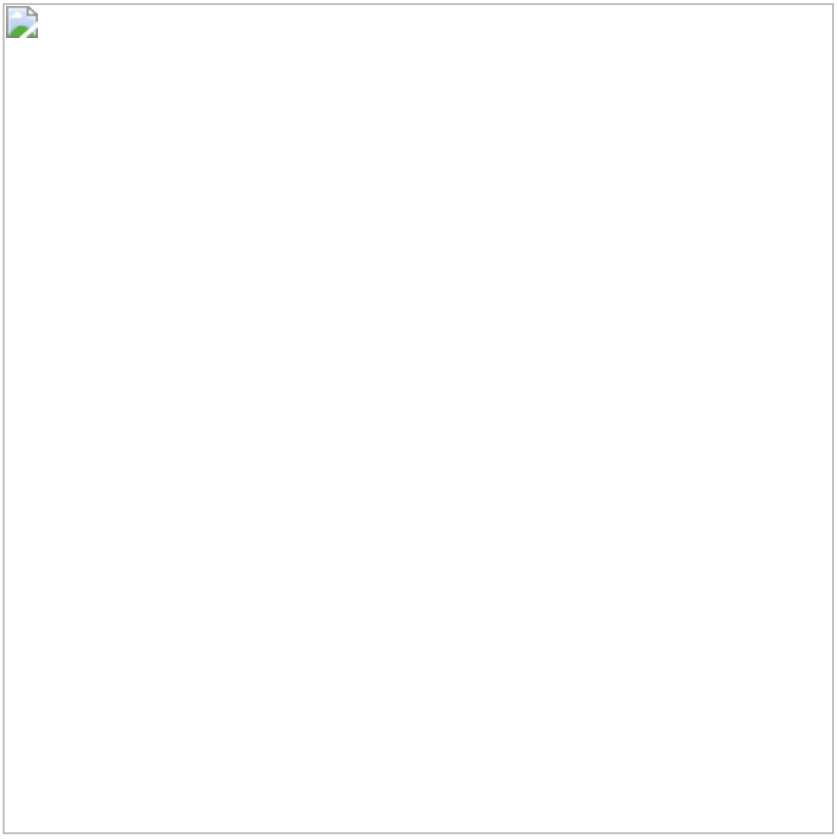

    - 장점 : 가운데 픽셀에 더 큰 가중치를 둠 → 더 선명한 output

- 최근 딥러닝에서는
  임의의 숫자로 초기화하고 → 학습시켜서
  해당 문제에 적합한 필터를 만듦

패딩 `padding`

- 필요성

    - 패딩이 없으면 합성곱 연산을 할 때마다 이미지가 계속 축소됨
    - 패딩이 없으면 이미지 가장자리의 픽셀은 단 한번만 사용됨. 정보를 버리게 됨.
- 해결방법
    - 이미지 테두리에 숫자 0으로 채운 패딩을 추가함.

스트라이드 합성곱 `strided convolution`

- **스트라이드 크기**
    - 필터가 한 번 이동할 때 몇 칸 움직이는지
    - 지금까지의 방법은 $s = 1$이었던 것

> 🌟 **[요약]**
>
> - 최종 이미지 크기
>
> → $\lfloor \frac{n+2p-f}{s} \rfloor + 1$
>
> - n : 이미지 크기
> - p : 패딩 크기
> - f : 필터 크기
> - 보통 홀수
> ▼ 이유
> 1. 짝수면 패딩이 비대칭
> 2. 홀수여야 중심위치가 존재함.
> - s : 스트라이드
> - 보통은 필터 크기가 정수가 되도록 p, s를 정함.

데이터가 3D일 때

2D	흑백 이미지
3D	컬러 이미지

[요약]

- 채널 수
  - 채널 = 3차원에서 깊이, 높이

이미지	필터	output
컬러 (RGB → 3)	이미지와 동일	사용한 필터 개수

  - 필터 개수

    = 탐지한 feature 개수

    = 윤곽선 종류 개수 (ex 수직, 수평, 7°, 36°, ...)

▼ ex) 필터 1개 썼을 때

▼ ex) 필터 여러 개 썼을 때

하나는 수직 윤곽선,

하나는 수평 윤곽선,

하나는 대각선

...

이런 식으로 쓸 수 있음.

구현

[요약]

- layer 종류 → 얘네를 조립해서 전체 신경망 만듦.

Convolution	(CONV)	합성곱 층
Pooling	(POOL)	풀링 층
Fully connected	(FC)	

- 출력층
  - layer 여럿 거치면서 3차원 output이 나왔겠지.
  - 그걸 1차원 벡터로 쫙 펴.
  - 그리고 softmax / logistic 회귀 함수에 넣어.
  - 그 결과 → predict한 값 (최종 output)
- 어떻게 조립할지
  - 직접 정하지 말고 문헌 중에 내 문제에 잘 작동할 것 같은 거 갖다 쓰기

▼ 흔한 ex)

CONV1 - POOL1

- CONV2 - POOL2

- FC3 - FC4 등 FC 몇 개

- SOFTMAX

합성곱 층

- 특징`feature`을 추출하는 역할

- 연산 순서 (layer 1개 기준)
  - 합성곱 연산 → 편향 추가 → 활성화 함수

- 합성곱 층 거듭할수록 이런 경향 有
  - height / width → 작아짐
  - #channel → 커짐

▼ 가중치 개수가 정말 줄었을까?

- 표기법
  - l : l번째 계층
  - $f^{[l]}$: 필터의 크기
  - $p^{[l]}$: 패딩의 양
  - $s^{[l]}$: 스트라이드 크기
  - n_H : 이미지의 높이
  - n_W : 이미지의 넓이
  - n_c : 채널의 수

- 합성곱 썼을 때
  - 한 layer 당 가중치 개수

    = 모든 필터의 원소 개수
  - $(f^{[l]} \times f^{[l]} \times n_c^{[l-1]}) \times n_c^{[l]}$

    (필터 1개 크기) × (필터 개수)
  - 추가된 편향까지 더하면 $+n_c^{[l]}$

- 합성곱 안 썼을 때

- 한 layer 당 가중치 개수

  = 가중치행렬 $W^{[l]}$의 크기

- $(n_H^{[l-1]} \times n_W^{[l-1]} \times n_c^{[l-1]}) \times (n_H^{[l]} \times n_W^{[l]} \times n_c^{[l]})$

Pooling 층

- 가중치 개수를 줄이는 역할

- 효과
  - height / width(표현의 크기)를 줄임

    → 계산 시간을 줄이고, 특징을 더 잘 검출해낼 수 있음.

- 종류 (2가지)

  ▼ Max Pooling ← 보통 이거 사용

  이유 : 최댓값만 남김 → 특징을 더 잘 남김

합성곱 층으로 치면 f = 2, s = 2, p = 0인데, 필터를 가지고 합성곱 연산 대신 Max/Average 연산을 하는 셈

▼ Average Pooling

- layer 개수 셀 때
  - 가중치 있는 층만 셀 거라서, Pooling 층은 안 셈.
  - 즉, 직전 합성곱 층 + 풀링 층 → 하나의 layer로 간주.

Fully connected 층

- 출력을 분류하는 역할